

He analizado conjuntamente los tres archivos: el PDF **trasladar_vinos_a_proyecto_minerales.pdf**, el notebook **Reto_Vino_Capitulo5_MULTIFUENTE.ipynb** y el inventario **CAPAS.pdf**. También he contrastado las decisiones metodológicas más delicadas con literatura sobre validación espacial, Positive-Unlabeled Learning y prospectividad mineral.

La conclusión central es esta:

El PDF tiene una base conceptual buena y entiende correctamente cuál es el verdadero problema. Pero todavía no describe un pipeline de prospectividad mineral de nivel experto.

Lo más importante que dice es correcto: no cambia tanto el algoritmo respecto al vino; cambian radicalmente la construcción de X, la construcción de y, el significado de los ceros y la validación.

Sin embargo, hay varias cuestiones que yo modificaría antes de empezar el MVP. Algunas son importantes y una de ellas revela incluso una pequeña fuga de información en el propio notebook del vino.

1. Qué representan realmente los tres archivos

El notebook del vino es esencialmente un **curso completo de Machine Learning tabular**. Recorre desde preprocessing, train/test y validación hasta regresión logística, árboles, KNN, SVM, Random Forest, boosting, XGBoost, LightGBM, Voting y Stacking. La clasificación binaria que más nos interesa define:

$$y = \begin{cases} 1 & \text{quality} \geq 70 \\ 0 & \text{quality} < 70 \end{cases}$$

y reserva un test aleatorio estratificado del 30 %.

El PDF **trasladar_vinos...** dice: conservemos esa **arquitectura conceptual de Data Science**, pero sustituyendo:

Vino	Prospectividad Au
Una fila = un vino	Una fila = una unidad espacial

Variables físicoquímicas	Variables geocientíficas
high_quality	target_Au
vino alta calidad = 1	indicio Au conocido = 1
vino no alta calidad = 0	background/pseudo-ausencia
predict_proba()	índice de favorabilidad
CV aleatoria	CV espacial
ROC-AUC	principalmente PR-AUC + ROC-AUC

Esa traducción es exactamente la que plantea el documento.

CAPAS . pdf, por su parte, nos dice qué materia prima tienes ya disponible: indicios mineros, litología, edades, GEODE, fallas/contactos/pliegues, MDT, red hidrográfica, geofísica y geoquímica multielemental, además de varios datasets maestros derivados.

Por tanto, los tres documentos encajan: **el notebook proporciona las técnicas de ML; CAPAS proporciona la información geocientífica; el PDF intenta definir el puente entre ambos.**

2. La primera corrección que haría: una fila no debe ser «un punto/celda»

El PDF dice:

Filas = puntos/celdas del territorio.

Para un diseño serio yo eliminaría esa ambigüedad.

La unidad estadística debería ser una celda territorial

Por ejemplo:

$celda_i \rightarrow (x_{i1}, x_{i2}, \dots, x_{ip}, y_i) \mid \text{text}\{celda\}_i \mid \rightarrow (x_{i1}, x_{i2}, \dots, x_{ip}, y_i)$

Una tabla conceptual podría ser:

cell_i	Au_ge	As_ge	dist_f	fault_density	lithol	slo	mag_ano	target
d	oq	oq	aull	_5km	ogy	pe	maly	_Au

C000 001	2.3	34	180	4.6	esqui sto	12	47	1
C000 002	0.4	7	6.200	0.3	caliza	4	-12	0
C000 003	1.1	19	870	2.1	granit o	9	35	?

Eso significa que **todos los datos deben terminar proyectándose sobre una geometría común.**

Los indicios BDMIN son puntos. Las fallas son líneas. La litología son polígonos. La geoquímica son rasters/polígonos. La geofísica puede tener diferentes soportes espaciales. El MDT es raster.

El modelo, sin embargo, necesita finalmente:

$$X \in R^{n \times p} \mid \text{in } \mathbb{R}^{n \times p}$$

donde n son celdas y p son variables.

Esta decisión parece trivial, pero no lo es. Define prácticamente todo el proyecto.

3. Antes del modelo hay que decidir la resolución espacial

Esto falta en el PDF y es una de las decisiones fundamentales.

Tú tienes, entre otras cosas, un MDT de 25 m y otro de 500 m.

Eso **no significa que debamos crear una predicción cada 25 metros.**

Si algunas de nuestras fuentes geocientíficas tienen una resolución efectiva mucho más gruesa, crear píxeles de 25 × 25 m produciría una falsa sensación de precisión.

Es el problema del **spatial support**: una variable medida/interpolada a escala kilométrica no adquiere más información porque la remuestreemos a 25 m.

Por eso la cadena debe ser:

resolución de fuentes → escala de los procesos geológicos → objetivo del modelo → resolución de la rejilla | text{resolución de fuentes} | \rightarrow | text{escala

de los procesos geológicos $\rightarrow$ *objetivo del modelo* $\rightarrow$ $\boxed{\text{resolución de la rejilla}}$

Yo probaría varias resoluciones razonables en el MVP y haría un análisis de sensibilidad. Por ejemplo, 500 m y 1 km pueden ser órdenes de magnitud sensatos para comparar en un modelo nacional, pero **no fijaría todavía una de ellas sin inspeccionar la resolución real y el soporte de geofísica y geoquímica.**

Este concepto es muy importante: **resolución de salida $\neq$ resolución real del conocimiento del modelo.**

4. Qué significa realmente X

El PDF da ejemplos:

dist_fault, fault_density_5km, Au_geog, As_geog, Sb_geog, elevation, slope, TPI, dist_stream, lithology, geological_age, etc.

Eso es correcto, pero hay que entender que tus archivos GIS **no son todavía las features.**

Por ejemplo:

contactosyfallas.gpkg

no debería entrar directamente en un Random Forest.

Hay que convertir esa capa en variables.

Podríamos obtener:

$dfault = \min_j d(celda, falla_j) d_{\{ \text{fault} \}} = \min_j d(\{ \text{celda} \}, \{ \text{falla}_j \})$

y además:

$density_{fault, 5km} = \frac{\text{longitud de fallas dentro de 5 km}}{\text{área}}$

y posiblemente:

$density_{fault, 1km}, density_{fault, 2km}, density_{fault, 5km}, density_{fault, 10km}$

Esto se denomina **feature engineering espacial**.

Y probablemente será mucho más importante para el resultado final que afinar un `max_depth` de 6 a 8.

5. Cómo convertiría realmente CAPAS .pdf en variables

Tu inventario contiene cuatro grandes bloques geológicos/geográficos y después geoquímica y geofísica.

Yo lo interpretaría así:

Fuente disponible	Variables que realmente debería recibir el ML
IndiciosII.gpkg	target_Au, calidad/confianza del indicio, cluster/deposito_id
litologias.gpkg	litología, grupo litológico, quizá jerarquía litológica
edades.gpkg	edad/unidad cronoestratigráfica
zonasgeode.gpkg	dominio/unidad geológica regional
contactosyfallas.gpkg	distancia a falla, densidad de fallas, tipo de falla, intersecciones, orientación, métricas multiescala
contactos.gpkg	distancia a contacto, densidad de contactos, combinación de litologías a ambos lados
ejes.gpkg	distancia a ejes de pliegues
estructuras de plegamiento	densidad/tipo de pliegues
buzamientos	estadísticos locales de dirección/inclinación
MDT	elevación, pendiente, curvatura, rugosidad, TPI...
red hidrográfica	distancia a drenaje, densidad de drenaje, quizá variables de cuenca
gravimetría	anomalía, residual/regional, gradientes, textura multiescala
magnetometría	anomalía magnética, gradientes, derivadas, textura
radiometría	canales y relaciones radiométricas si existen
magnetotelúrico	variables resistivas/conductivas disponibles
petrofísica	variables físicas relevantes según contenido
Au/As/Sb/Bi/Hg/Cu/Pb/Zn/W	concentraciones, anomalías, transformaciones y asociaciones multielementales

Esto ya es mucho más cercano al dataset de ML.

6. Una distinción crítica dentro de CAPAS .pdf: rasters analíticos frente a rasters RGB

Tienes dos familias distintas de geoquímica.

Una son los TIFF analíticos:

AtlasGeoquimico_Au_Sedimentos_2012.tif,
As, Sb, Bi, Hg, Cu, Pb, Zn, W.

Y otra son versiones _RGB.tif creadas para visualizar en QGIS.

Para ML:

usar TIFF analítico \boxed{\text{usar TIFF analítico}}

y

NO usar TIFF RGB \boxed{\text{NO usar TIFF RGB}}

Un raster RGB contiene el **color utilizado para representar una concentración**, no necesariamente la concentración.

Si un píxel rojo corresponde a determinada concentración, sus valores [R,G,B] son propiedades de la simbología.

Introducir ese raster en el modelo equivale a enseñarle una representación gráfica de la variable.

Las capas RGB son para QGIS.

Las capas analíticas son para Data Science.

7. Tampoco metería simultáneamente todas las representaciones de una misma variable

En CAPAS .pdf aparece geoquímica como raster analítico, raster RGB y vector poligonal.

Si Au.tif y geoquimica_oro_sedimentos_2012.gpkg representan esencialmente la misma información, no introduciría ambas simplemente porque existan.

Eso genera redundancia:

$$XAu, raster \approx XAu, polygon \quad X\{Au, raster\} \setminus approx X\{Au, polygon\}$$

y puede distorsionar importancias y análisis.

Primero hay que decidir cuál es la **representación canónica** de cada fuente.

8. Pipeline: el PDF acierta completamente en el concepto

El documento propone:

```
master_Au
  ↓
preprocessing
  ↓
Random Forest / XGBoost
  ↓
P(Au)
```

y señala correctamente que utilizar Pipeline evita que imputaciones/codificaciones se calculen utilizando el test.

Esto es una idea esencial.

Si calculamos, por ejemplo:

$median(As)median(As)$

usando todos los datos antes de dividirlos, el entrenamiento conoce indirectamente información de validación.

Lo correcto es que en cada fold:

$Train_k \rightarrow fit(imputer) Train_k \rightarrow fit(imputer)$

y después:

$Validation_k \rightarrow transform(imputer\ entrenado) Validation_k \rightarrow transform(imputer\ entrenado)$

Scikit-learn Pipeline + GridSearchCV hace precisamente eso cuando está bien construido.

9. Pero aquí he detectado un problema real en el notebook del vino

El PDF afirma que el notebook implementa bien esta filosofía.

Conceptualmente sí.

Pero el notebook **realiza antes una imputación global de valores faltantes**:

```
_med = df[_col].median()  
df[_col] = df[_col].fillna(_med)
```

antes de los splits posteriores.

Esto significa que la mediana se ha calculado con:

$Train + Test Train + Test$

y después más adelante vuelve a aparecer un SimpleImputer dentro del pipeline.

La segunda imputación ya no puede reparar la primera, porque los NaN han desaparecido.

Por tanto:

hay una pequeña fuga de información en el notebook `\boxed{\text{hay una pequeña fuga de información en el notebook}}`

No destruye su utilidad didáctica, pero **yo no copiaría esa parte al proyecto mineral**.

En nuestro proyecto, los valores ausentes deben permanecer como NaN hasta el pipeline.

Esta es probablemente la corrección técnica más concreta que haría a la relación PDF ↔ notebook.

10. Además, en geociencias «missing» no siempre significa «valor desconocido cualquiera»

Esto es incluso más importante que en el vino.

Supongamos que no tenemos magnetometría para una determinada zona.

No significa:

“la anomalía magnética seguramente está cerca de la mediana española”.

Significa:

“esta zona no fue cubierta por ese dataset / no tenemos observación”.

Son situaciones distintas.

Por ello, dependiendo de las capas, pueden interesar variables como:

`magnetic_missing = {1 sin cobertura 0 con cobertura magnetic\_missing = \begin{cases} 1 & \text{sin cobertura} \\ 0 & \text{con cobertura} \end{cases}}`

Pero aquí existe otro riesgo: **la ausencia de cobertura puede codificar el esfuerzo histórico de exploración**.

Y el modelo podría descubrir:

zonas investigadas → más minas conocidas

en lugar de:

determinada geología → más mineralización.

Esto se denomina **sampling/exploration bias** y el PDF apenas lo trata.

11. Numéricas y categóricas: lo que propone es correcto como baseline

El PDF propone:

numéricas → imputación mediana
numéricas → imputación mediana $\rightarrow$ *imputación mediana*
categóricas → imputación + OneHotEncoder
categóricas → imputación + OneHotEncoder $\rightarrow$ *imputación + OneHotEncoder*

Perfectamente válido para empezar.

Pero no lo convertiría en una regla universal.

Por ejemplo, para Logistic Regression, KNN o SVM conviene escalar:

$$x' = \frac{x - \mu}{\sigma}$$

En Random Forest/XGBoost/LightGBM el escalado normalmente no aporta nada esencial porque los árboles operan mediante umbrales.

Por tanto tendremos **pipelines específicos por familia de modelos**.

El propio notebook termina haciendo esto razonablemente bien: el pipeline de clasificación incluye StandardScaler, mientras que el Random Forest usa un preprocessing sin escalado.

12. One-hot puede quedarse corto para vuestra geología

En el vino solo existe una categórica relativamente sencilla: type.

En vuestro problema podríamos encontrarnos cientos de litologías/unidades geológicas.

Si hacemos:

```
lithology_A  
lithology_B  
lithology_C  
...  
lithology_438
```

la dimensionalidad puede crecer muchísimo.

Antes de entrenar habría que examinar:

cardinality(X_j)

y agrupar categorías extremadamente raras.

También estudiaría categorías jerárquicas:

```
unidad detallada  
  ↓  
litología  
  ↓  
grupo litológico  
  ↓  
familia geológica
```

Incluso añadiría **CatBoost** al benchmark si las variables categóricas terminan siendo numerosas, ya que está específicamente bien adaptado a datos tabulares con categóricas. No sustituye a RF/XGBoost/LightGBM, pero sí merece competir con ellos.

13. Random Forest: por qué tiene sentido aquí

El PDF lo propone como baseline fuerte.

Tiene lógica.

Un árbol aprende reglas como:

$As > 50 \mid dist_fault < 1200 \mid lithology = metasedimentary$

y después:

$favorabilidad_alta$

Random Forest crea muchos árboles utilizando muestras bootstrap y subconjuntos aleatorios de features.

Su salida es aproximadamente:

$$\hat{p}(x) = \frac{1}{T} \sum_{t=1}^T \hat{p}_t(x) \quad \text{donde } \hat{p}(x) = \frac{1}{T} \sum_{t=1}^T \hat{p}_t(x)$$

Esto permite capturar relaciones muy no lineales.

Por ejemplo:

As elevado puede ser favorable solamente cuando estamos cerca de determinadas fallas y dentro de determinada litología.

Una regresión logística necesita que nosotros modelemos explícitamente esas interacciones.

Un Random Forest puede encontrarlas.

El notebook además optimiza `max_depth`, `min_samples_leaf`, `max_features` y `class_weight`.

Perfectamente reutilizable.

14. Pero el OOB score del Random Forest NO me serviría como validación espacial

El notebook utiliza:

`oob_score=True`

y muestra OOB accuracy.

En datos i.i.d. puede ser útil.

Pero en nuestro caso los ejemplos OOB continúan estando rodeados espacialmente de celdas muy similares utilizadas por otros árboles.

Por ello:

OOB no sustituye Spatial CV \boxed{\text{OOB no sustituye Spatial CV}}

Puede mostrarse como diagnóstico interno, pero no como estimación realista de generalización geográfica.

15. XGBoost y LightGBM: por qué son especialmente interesantes

El PDF dice correctamente que el problema tendrá estructura tabular:

Au | As | Sb | dist_fault | lithology | slope | ...

y que boosting suele funcionar muy bien en ese contexto.

La diferencia fundamental respecto a RF es conceptual.

Random Forest construye muchos árboles relativamente independientes:

Tree1, Tree2,...TreeT *Tree_1, Tree_2, dots Tree_T*

Boosting construye árboles secuencialmente:

$F_m(x) = F_{m-1}(x) + \eta f_m(x)$ $F_m(x) = F_{\{m-1\}}(x) + \eta f_m(x)$

Cada nueva etapa intenta reducir los errores que permanecen.

learning_rate = \eta controla cuánto aporta cada árbol.

En XGBoost tendremos variables como:

n_estimators, learning_rate, max_depth, min_child_weight, subsample, colsample_bytree, reg_alpha, reg_lambda.

El notebook usa ya subsample=.85 y colsample_bytree=.85.

LightGBM utiliza una estrategia de crecimiento diferente y parámetros como num_leaves, min_child_samples, etc.

Yo mantendría ambos.

16. No empezaría con redes neuronales

Aquí coincido completamente con el PDF.

Para un MVP con variables tabulares heterogéneas, cantidades probablemente limitadas de positivos y necesidad de interpretación, empezaría:

Logistic → *RF* → *ExtraTrees* → *XGBoost* → *LightGBM* → *CatBoost* *Logistic* | *rightarrow* *RF* | *rightarrow* *ExtraTrees* | *rightarrow* *XGBoost* | *rightarrow* *LightGBM* | *rightarrow* *CatBoost*

y solo después estudiaría arquitecturas más complejas.

La mayor incertidumbre de vuestro proyecto ahora mismo **no es la capacidad del algoritmo.**

Es:

labels + sampling + spatial validation + feature engineering | *boxed* { | *text*{*labels*} + | *text*{*sampling*} + | *text*{*spatial validation*} + | *text*{*feature engineering*} }

17. Spatial Cross-Validation: probablemente la parte más importante del PDF

Este apartado está muy bien encaminado.

El documento explica que, si existen tres minas del mismo distrito:

A ---- B ---- C

y A+B entran en train mientras C entra en validación, el modelo prácticamente ya ha visto el contexto geológico de C.

Resultado:

$Performance_{random} > Performance_{real} > Performance_{\{random\}} > Performance_{\{real\}}$

por autocorrelación espacial.

El PDF propone bloquear España y utilizar grupos espaciales.

Esto coincide con la literatura metodológica: la validación aleatoria sobre datos espacialmente estructurados suele infraestimar el error real y los folds espaciales son preferibles cuando queremos generalizar geográficamente.

18. Pero GroupKFold por sí solo no resuelve el problema

Aquí desarrollaría bastante más el PDF.

Imaginemos dos bloques:

| bloque A | bloque B |
 ↑
 frontera

Una mina situada 10 metros dentro del bloque B puede tener observaciones de entrenamiento 20 metros al otro lado, dentro de A.

Formalmente están en grupos distintos.

Geológicamente siguen siendo casi idénticas.

Por eso el tamaño del bloque debería relacionarse con una escala de independencia espacial.

Una aproximación sería estudiar autocorrelación espacial mediante variogramas/correlogramas o analizar a qué distancia disminuye de forma relevante la similitud de covariables.

La propia literatura recomienda que el blocking refleje la estructura de dependencia y el objetivo predictivo.

Yo probaría además **buffered spatial CV**, dejando una zona de seguridad alrededor de los bloques de validación.

19. Introduciría dos tipos de validación espacial, no uno

Esto es muy importante conceptualmente.

Tipo A: interpolación espacial

Pregunta:

¿Puede el modelo encontrar nuevos targets dentro de regiones geológicas aproximadamente representadas durante el entrenamiento?

Spatial Block CV.

Tipo B: transferencia geológica/greenfield

Pregunta:

¿Puede funcionar en un distrito o dominio geológico que no ha visto?

Leave-one-district-out o leave-one-metallogenic-domain-out.

Son preguntas distintas.

Un modelo podría hacer:

$PR-AUC_{interpolation}=0.75$ $PR\backslash text{-}\backslash AUC_{\{interpolation\}}=0.75$

pero:

$PR-AUC_{new\ domain}=0.35$ $PR\backslash text{-}\backslash AUC_{\{new\ domain\}}=0.35$

y eso sería información tremendamente valiosa.

Decir simplemente «Spatial CV» es demasiado genérico.

20. Tampoco separaría train/test principalmente por comunidades autónomas

El PDF utiliza Galicia, Asturias, Castilla y León, etc. solo como ejemplo y aclara que no necesariamente deben ser CCAA.

Correcto.

Las fronteras administrativas no son fronteras geológicas.

Preferiría:

spatial blocks \ *text{spatial blocks}*

y posiblemente:

metalogenic/geological domains \ *text{metalogenic/geological domains}*

como segunda estrategia de validación.

21. El siguiente salto de nivel es Nested Spatial Cross-Validation

Esto falta en el PDF.

Supongamos:

```
GridSearchCV(..., cv=spatial_cv)
```

y después informamos del mejor PR-AUC de ese mismo proceso.

Hemos utilizado esos folds para elegir:

`max_depth`, `learning_rate`, `num_leaves`, etc.

Por tanto esa métrica también ha influido en la selección.

Para una evaluación más estricta:

Outer Spatial CV \boxed{\text{Outer Spatial CV}}


para evaluar el modelo

y dentro de cada fold:

Inner Spatial CV \boxed{\text{Inner Spatial CV}}

para ajustar hiperparámetros.

Es decir:



Esto proporciona una estimación mucho más limpia de la capacidad de generalización.

22. El problema de los ceros: el PDF identifica perfectamente el núcleo del problema

Este es probablemente el mejor apartado del documento.

En vinos:

$y=0$

significa:

sabemos que no es un vino de calidad alta.

En vuestro proyecto:

$$y=0$$

no significa necesariamente:

sabemos que no existe oro.

Significa:

no conocemos allí un indicio.

El propio PDF lo formula correctamente como **background / pseudo-ausencias** y lo aproxima a Positive-Unlabeled Learning.

Esta no es solo una observación teórica. Existe investigación específicamente en mineral prospectivity mapping aplicando PU Learning precisamente porque seleccionar negativos fiables es problemático.

23. Qué es realmente Positive-Unlabeled Learning

Nuestro dataset conceptual no es:

$$P+NP+N$$

sino:

$$P+UP+U$$

donde:

$$P=\text{positive}$$

y:

$$U=\text{unlabeled}$$

Dentro de U hay dos poblaciones:

$$U = N \cup P_{\text{unknown}} \quad U = N \cup P_{\text{unknown}}$$

Es decir:

UNLABELED

- |— realmente negativos
- |— mineralizados aún desconocidos

Cuando nosotros arbitrariamente etiquetamos algunos U como $\emptyset$, estamos creando **pseudo-negativos**.

Por ello el modelo inicialmente aprendería:

$$P(y = \text{indicio conocido}) P(y = \text{indicio conocido})$$

mucho más directamente que:

$$P(y = \text{mineralización real}) P(y = \text{mineralización real})$$

Esta diferencia filosófica es central.

24. El buffer de 5 km del PDF no debería convertirse en una constante

El documento propone como ejemplo:

$$\text{buffer} = 5 \text{ km} \quad \text{buffer} = 5 \text{ km}$$

alrededor de ocurrencias conocidas.

Lo tomaría únicamente como hipótesis inicial.

No existe un 5 km universal.

Deberíamos estudiar:

$$r \in \{1, 2, 5, 10, \dots \text{ km}\} \quad r \in \{1, 2, 5, 10, \dots \text{ km}\}$$

y observar sensibilidad.

El radio debería depender, entre otras cosas, del tipo de yacimiento, precisión espacial de BDMIN, escala de clusterización de ocurrencias y resolución de la rejilla.

También deberíamos **agrupar indicios que pertenezcan al mismo sistema mineralizado**.

Si un depósito tiene 15 registros BDMIN muy próximos, estadísticamente no deberíamos permitir que esos 15 puntos se comporten como 15 descubrimientos independientes.

25. Necesitamos auditar los positivos antes de cualquier ML

CAPAS.pdf identifica IndiciosII.gpkg como target.

Pero antes de generar target_Au, necesitamos saber exactamente qué significa un registro de Au.

Por ejemplo:

¿Au es sustancia principal o secundaria?

¿Es mina, indicio, manifestación, recurso?

¿Existen duplicados históricos?

¿Hay varios puntos pertenecientes al mismo depósito?

¿Qué precisión tienen las coordenadas?

¿Hay registros desplazados?

¿Incluye explotaciones antiguas y modernas?

¿Existe tipología de yacimiento?

Todo esto afecta a y.

Un artículo reciente dedicado específicamente a la **representatividad de etiquetas en mineral prospectivity mapping** subraya precisamente que la elección de lo que consideramos clase positiva condiciona el significado y fiabilidad del mapa.

Por eso antes de `03_Pseudo_Ausencias_Dataset.ipynb` introduciría:

`01_Auditoria_Labels_Au.ipynb` $\boxed{\text{\textit{01_Auditoria_Labels_Au.ipynb}}}$

26. Hay otro sesgo incluso más peligroso: el esfuerzo de exploración

España no ha sido investigada uniformemente.

Determinadas zonas tienen más:

minería histórica, campañas geoquímicas, sondeos, cartografía detallada, accesibilidad, exposiciones rocosas, investigación universitaria, exploración empresarial.

Por tanto:

$P(\textit{indicio registrado})P(\text{\textit{indicio registrado}})$

depende parcialmente de:

$P(\textit{mineralización}) \times P(\textit{haber sido explorado/detectado})P(\text{\textit{mineralización}}) \\ \times P(\text{\textit{haber sido explorado/detectado}})$

Este es un sesgo fundamental de presencia-only data.

Si elegimos background completamente al azar por España mientras los positivos están concentrados en regiones intensamente exploradas, el modelo puede aprender características de la **exploración**, no necesariamente de la mineralización.

Esto debería convertirse en una fase explícita del proyecto.

27. No generaría un único conjunto de pseudo-ausencias

Yo haría varias realizaciones.

Por ejemplo:

$Background_1, \dots, Background_{20} \quad Background_1, \dots, Background_{20}$

Cada una con una semilla distinta y respetando las restricciones espaciales.

Después:

$Model_1, \dots, Model_{20} \quad Model_1, \dots, Model_{20}$

Esto nos permite medir algo que el PDF tampoco aborda suficientemente:

$\text{incertidumbre debida al background} \quad \boxed{\text{incertidumbre debida al background}}$

Una celda podría tener:

$\bar{p}=0.82 \quad \bar{p}=0.82$

pero:

$\sigma_p=0.25 \quad \sigma_p=0.25$

Eso es muy distinto de:

$\bar{p}=0.82, \sigma_p=0.03 \quad \bar{p}=0.82, \quad \sigma_p=0.03$

Aunque ambos mapas de favorabilidad enseñen 0.82.

28. PR-AUC: el PDF acierta, pero existe un matiz importante

El documento propone PR-AUC como métrica principal porque la mineralización es rara.

Correcto.

La literatura clásica también muestra que Precision-Recall suele ser más informativa que ROC cuando las clases están muy desbalanceadas.

Recordemos:

$Precision = \frac{TP}{TP+FP} \quad Recall = \frac{TP}{TP+FN}$

La curva PR estudia el compromiso:

¿cuántos verdaderos positivos recupero?

frente a:

¿qué fracción de mis predicciones positivas acierta?

Perfecto para búsqueda mineral.

29. Pero PR-AUC depende de la prevalencia del conjunto de evaluación

Este es un punto avanzado que falta en el PDF.

Supongamos que nosotros fabricamos:

100 positivos

100 background

o:

100 positivos

10.000 background

La precisión cambia radicalmente.

Por tanto:

$PR-AUC_{PR} \setminus \text{text{-}}AUC$

no es totalmente independiente de cómo hayamos muestreado el background.

Eso significa que **no debemos comparar PR-AUC de experimentos que utilicen ratios de background diferentes como si fueran directamente equivalentes.**

La comparación de modelos debe utilizar exactamente los mismos folds y el mismo esquema de pseudo-ausencias.

30. Añadiría una métrica mucho más ligada al negocio de exploración

Supongamos que el modelo ordena España de mayor a menor favorabilidad.

Una pregunta operativa muy relevante es:

¿Qué porcentaje de indicios Au retenemos si investigamos únicamente el 5 % del territorio mejor clasificado?

Por ejemplo:

Top 5% area → 65% deposits $Top\ 5\% \mid area \mid \rightarrow 65\% \mid deposits$

o:

Top 10% area → 82% deposits $Top\ 10\% \mid area \mid \rightarrow 82\% \mid deposits$

Esto se suele estudiar mediante **success-rate / concentration-area curves**, y es especialmente interpretable para prospectividad porque la finalidad es reducir el área de búsqueda. Este tipo de evaluación aparece habitualmente en MPM.

Para vosotros puede resultar incluso más útil que decir:

ROC-AUC = 0.87.

31. Mis métricas finales serían conceptualmente cuatro familias

No me limitaría a una cifra.

Tendríamos discriminación:

PR-AUC, ROC-AUC $PR\text{-}AUC, \mid ROC\text{-}AUC$

clasificación operativa:

Precision, Recall, F1, Fβ $Precision, \mid Recall, \mid F1, \mid F_{\beta}$

priorización espacial:

Recall@Top1%, Recall@Top5%, Recall@Top10%
Recall@Top1 | %, Recall@Top5 | %, Recall@Top10 | %

y fiabilidad:

Brier, Calibration, incertidumbre
Brier, | Calibration, | incertidumbre

Pero hay que tener muchísimo cuidado con la última.

32. El Brier Score no demuestra automáticamente «probabilidad geológica»

El PDF menciona Brier score como calibración y después, acertadamente, dice que $\text{predict_proba} = 0.83$ no debe interpretarse directamente como un 83 % de probabilidad de oro.

Esta segunda afirmación es crucial.

Con pseudo-ausencias:

$\hat{p} = 0.83 \mid \text{hat } p = 0.83$

puede significar:

el modelo considera esta celda extremadamente parecida a los positivos frente al background usado para entrenar.

Pero no necesariamente:

hay una probabilidad geológica del 83 % de que aquí exista oro.

Porque la prevalencia real:

$P(\text{Au})P(\text{Au})$

es desconocida.

Y además hemos manipulado artificialmente:

$$\frac{N_{positive}}{N_{background}}$$

durante el entrenamiento.

Yo hablaría de:

$$\boxed{\text{Prospectivity Score}}$$

o:

$$\boxed{\text{Índice de favorabilidad}}$$

al menos durante el MVP.

Aquí el PDF está muy bien orientado.

33. Feature importance: bien, pero SHAP tampoco es «la verdad geológica»

El documento propone permutation importance y SHAP.

Correcto.

Pero hay tres niveles.

Random Forest puede dar:

$$\text{ImpurityImportance}_j$$

El notebook hace eso y lo complementa con permutation importance.

La permutation importance mide cuánto empeora el rendimiento si destruimos información de una feature:

$$\text{Importance}_j = \text{Score}(X) - \text{Score}(\text{Permute}(X_j))$$

Eso es más interpretable.

SHAP intenta descomponer para una observación:

$$f(x) = E[f(X)] + \sum_j \phi_j f(x) = E[f(X)] + \sum_j \phi_j$$

donde ϕ_j es la contribución asignada a la feature j .

Por ejemplo:

As_geoq	+0.18
dist_fault	+0.14
lithology_schist	+0.10
Sb_geoq	+0.07
slope	-0.02

Muy útil.

Pero:

SHAP ≠ causalidad *SHAP ≠ causalidad*

34. Features correlacionadas complican mucho la interpretación

Supongamos:

$Au \leftrightarrow As \leftrightarrow Sb$ $Au \rightarrow As \rightarrow Sb$

y también:

$dist_fault1km \leftrightarrow dist_fault2km \leftrightarrow fault_density$
 $dist_fault1km \rightarrow dist_fault2km \rightarrow fault_density$

El modelo puede distribuir la señal entre variables correlacionadas de diferentes maneras.

Una ejecución podría decir:

As = importancia 0.20
Sb = 0.05

y otra:

As = 0.09
Sb = 0.15

aunque la información conjunta sea parecida.

Por eso yo estudiaría:

importancia por grupos de variables \text{importancia por grupos de variables}

como:

Geoquímica
Estructural
Litología
Geofísica
Topografía
Hidrología

además de cada variable individual.

Esto es mucho más geológicamente interpretable.

35. Y la permutation importance no debería calcularse únicamente sobre TRAIN

El notebook del vino calcula permutation importance sobre entrenamiento y señala que es para interpretación.

Para nuestro proyecto preferiría obtenerla mediante predicciones OOF o sobre folds espaciales nunca vistos.

Porque queremos responder:

¿Qué variables son importantes para generalizar?

no:

¿Qué variables utilizó el modelo para aprender el training set?

Diferencia sutil, pero importante.

36. Voting: qué significa exactamente

El notebook combina por ejemplo SVM + RF + boosting mediante `VotingClassifier(voting='soft')`.

Si:

$$p_{RF}=0.8, p_{XGB}=0.7, p_{SVM}=0.9$$

un soft voting sencillo podría hacer:

$$p_{ensemble} = \frac{0.8+0.7+0.9}{3} = 0.8$$

La idea funciona si los modelos tienen errores complementarios.

Si todos fallan exactamente en las mismas zonas, combinarlos aporta poco.

Por eso el PDF dice correctamente que no probaría ensembles complejos hasta haber entendido bien los modelos individuales.

Estoy de acuerdo.

37. Pero soft voting tiene otro requisito: probabilidades comparables

Si RF es muy optimista:

$$p_{RF}=0.95$$

y XGB es conservador:

$$p_{XGB}=0.65$$

aunque tengan capacidades de ranking parecidas, promediar directamente sus probabilidades puede hacer que RF domine.

Por eso, antes de Voting probabilístico, evaluaría:

$$\text{calibration}_{RF} \quad \text{calibration}_{XGB} \quad \text{calibration}_{LGBM}$$

o emplearía combinaciones basadas en rankings si la calibración absoluta no es fiable.

38. Stacking necesita una corrección muy importante para vuestro proyecto

El notebook usa:

```
StackingClassifier(  
    ...  
    cv=3  
)
```

y genera meta-features OOF.

Esto está bien en el reto del vino.

Pero **no debemos copiarlo literalmente**.

Ese cv=3 ordinario volvería a mezclar espacialmente las observaciones.

Para el proyecto de oro el stacking debe generar:

OOFRFOOF_{RF} OOFXGBOOF_{XGB} OOFLGBMOOF_{LGBM}

mediante **folds espaciales**.

Entonces:

```
RF spatial OOF  ┌  
XGB spatial OOF ┤ ──> meta-modelo  
LGB spatial OOF └
```

No dejaría esta parte al `StackingClassifier(cv=3)` por defecto.

Probablemente construiría el stacking espacial manualmente.

39. Algo importante sobre el notebook multifuente: no usaría sus resultados como evidencia científica

El notebook se presenta como «MULTIFUENTE (14 fuentes)».

Sin embargo, en la ejecución almacenada muchas fuentes fallaron o fueron omitidas; las fuentes finalmente listadas son uci, datasets_red, datasets_white y tidyTuesday, y esta última aparece con cero registros con las variables normalizadas necesarias para el modelado Wine Quality.

Además datasets_red y datasets_white parecen ser mirrors/versiones de los Wine Quality datasets originales.

Por ello:

usar el notebook como plantilla didáctica $\boxed{\text{usar el notebook como plantilla didáctica}}$

sí.

Pero:

usar sus rankings de algoritmos como prueba de que ganará en Au $\boxed{\text{usar sus rankings de algoritmos como prueba de qué ganará en Au}}$

no.

Eso solo podrá decidirlo vuestra Spatial CV.

40. También corregiría ligeramente la idea de los «datasets maestros» actuales

CAPAS.pdf contiene:

Indicios_Master_Geocientifico_BDMIN,
Indicios_con_Geoquimica_y_MDT_BDMIN,
Indicios_con_Geoquimica_Completa_BDMIN, etc.

Por los nombres parecen tablas construidas **alrededor de los indicios BDMIN**.

No puedo afirmar el contenido exacto sin abrir esos GPKG/CSV, porque los tres archivos que me has pasado solo contienen sus nombres.

Pero, **si efectivamente cada fila corresponde a un indicio**, esos ficheros todavía no son el master_Au final.

Son algo parecido a:

dataset de positivos enriquecidos

El modelo necesita:

TODAS LAS CELDAS DEL TERRITORIO

+

features

+

target/background

Es decir, necesitamos construir:

Grid_Master_Au | *boxed*{ | *text*{*Grid* | *Master* | *Au*}}

No únicamente:

Indicios_Master_Au | *text*{*Indicios* | *Master* | *Au*}

Esta distinción es fundamental.

41. El dataset final debería tener aproximadamente esta arquitectura

Conceptualmente:

Grupo

Ejemplos

Identidad espacial	cell_id, x, y, spatial_block, metallogenic_domain
Target	target_Au, label_type, deposit_cluster_id
Litología	lithology, age, geode_zone, categorías generalizadas
Estructural	dist_fault, dist_contact, densidades 1/2/5/10 km, intersecciones
Pliegues	distancia a ejes, densidad, orientación
Geoquímica	Au, As, Sb, Bi, Hg, Cu, Pb, Zn, W + transformaciones
Geofísica	anomalías y derivados
Topografía	elevation, slope, TPI, curvature, roughness
Hidrología	dist_stream, drainage density
Calidad	indicadores de cobertura/missingness
Validación	spatial_fold, outer_fold, quizá domain_fold

Entonces cada fila sí sería autocontenida:

$X_i, y_i | X_{-i}, y_{-i}$

42. Geoquímica: no utilizaría únicamente las concentraciones brutas

Tienes exactamente los elementos que esperaba que fueran útiles para un MVP de oro: Au, As, Sb, Bi, Hg, Cu, Pb, Zn y W.

Además del valor original podría estudiar transformaciones robustas.

Muchas concentraciones geoquímicas tienen distribuciones altamente asimétricas:

$$x' = \log_{10}(1+x) \quad x' = |\log(1+x)|$$

También puede resultar interesante definir anomalía respecto a su entorno geológico:

$$z_{local} = \frac{x - \mu_{province}}{\sigma_{province}} \quad z_{local} = \frac{x - \mu_{province}}{\sigma_{province}}$$

porque, por ejemplo, As=50 puede ser extremadamente anómalo en una unidad y bastante normal en otra.

Esto permite al modelo distinguir:

$$valor_absoluto \mid \text{valor_absoluto}$$

de:

anomalía respecto al background geológico \text{anomalía respecto al background geológico}

que geológicamente puede ser mucho más útil.

43. También estudiaría interacciones geoquímicas, pero no cientos al azar

Por ejemplo:

Au+As+Sb+Bi $Au + As + Sb + Bi$

puede ser más informativo que cada elemento aislado.

Se podrían construir variables como:

Au×As $Au \times As$

o ratios/contrastes cuando tengan justificación geológica.

Pero no haría automáticamente:

$\frac{x_i}{x_j}$

para todas las parejas.

Con 20 elementos tendríamos cientos de interacciones y generaríamos ruido.

La regla debería ser:

geological hypothesis → *feature* \boxed{\text{geological hypothesis}} \rightarrow \text{feature}

y después ML prueba si realmente aporta información.

44. Las variables estructurales deberían ser multiescala

Esto tampoco aparece suficientemente desarrollado en el PDF.

Una falla a 200 metros puede importar.

Pero también puede importar la pertenencia a un corredor estructural regional.

Por tanto:

fault_density1km *fault_density_{1km}* *fault_density2km* *fault_density_{2km}*
fault_density5km *fault_density_{5km}* *fault_density10km* *fault_density_{10km}*

y quizá:

dist_fault_intersection *dist_fault_intersection*
n_fault_intersections5km *n_fault_intersections_{5km}*

pueden capturar procesos distintos.

Exactamente el mismo principio puede aplicarse a contactos y pliegues.

Esto es **multi-scale feature engineering**.

Para prospectividad geológica, considero que será una de las fases con mayor retorno de todo el proyecto.

45. Geofísica tampoco debería entrar como una sola variable por capa

gravimetria.gpkg y *magnetometria* *radiometria.gpkg* son fuentes, no necesariamente features finales.

Dependiendo de lo que contengan, podríamos derivar:

valor original, anomalía regional/residual, gradiente, diferencia respecto al entorno, textura, media/desviación en ventanas, máximos/mínimos locales.

Es decir:

$$G(x,y)G(x,y)$$

se puede transformar en:

$$GG \nabla G - G_{\text{regional}} \sigma(G)_{5km} \sigma(G)_{5km}$$

etc.

Pero para decir exactamente cuáles hay que crear necesito inspeccionar el esquema real de esos GPKG/rasters, no únicamente sus nombres.

46. Añadiría una fase completa que el PDF no tiene: incertidumbre

Un mapa que solamente diga:

$$\text{favorabilidad} = 0.91$$

es insuficiente.

Querría además saber:

¿cuánto cambia con otro fold?

¿cuánto cambia con otras pseudo-ausencias?

¿cuánto cambia con otra semilla?

¿cuánto cambia entre RF/XGB/LGBM?

Por ejemplo:

$$\text{MeanProspectivity}_i = \frac{1}{M} \sum_m p_{im} \text{MeanProspectivity}_i = \frac{1}{M} \sum_m p_{im}$$

y:

$$\text{Uncertainty}_i = SD(p_{i1}, \dots, p_{iM}) \text{Uncertainty}_i = SD(p_{i1}, \dots, p_{iM})$$

Entonces tendríamos:

Mapa 1: favorabilidad.

Mapa 2: incertidumbre.

Una zona:

$score=0.90, uncertainty=0.03$ $score=0.90, | uncertainty=0.03$

merece una interpretación distinta de:

$score=0.90, uncertainty=0.31$ $score=0.90, | uncertainty=0.31$

47. Y añadiría un Area of Applicability

Esta es otra carencia importante.

Imaginemos una celda cuya combinación:

litología
geoquímica
geofísica
estructura

no se parece a nada utilizado durante el entrenamiento.

Un Random Forest puede dar igualmente:

$p=0.87$ $p=0.87$

pero está extrapolando.

El concepto **Area of Applicability (AOA)** intenta distinguir dónde el modelo opera dentro de un espacio de predictores representado por los datos de entrenamiento y dónde estamos extrapolando. Meyer y Pebesma proponen precisamente acompañar las predicciones espaciales con un mapa de aplicabilidad/dissimilarity.

Yo terminaría generando al menos:

Prospectivity_Au.tif
Uncertainty_Au.tif
Applicability_Au.tif

Esto convertiría el mapa en una herramienta mucho más profesional.

48. Hay una diferencia entre «modelo favorable» y «modelo geológicamente correcto»

El PDF sugiere utilizar SHAP para comprobar:

¿el modelo está aprendiendo geología razonable?

Muy buen principio.

Pero añadiría una advertencia.

Si el modelo dice:

`distancia_a_carretera = variable nº1`

y obtiene un PR-AUC extraordinario, probablemente tenemos un problema de bias de exploración.

Si dice:

`cobertura_geofisica = variable nº1`

también.

Por eso hay que diferenciar:

predictive signal \ *text{predictive signal}*

de:

metallogenic signal \ *text{metallogenic signal}*

No todas las variables predictivas son causal o geológicamente útiles.

49. Cómo corregiría la arquitectura de notebooks que propone el PDF

El documento propone:

01_EDA_BDMIN_Au
02_Feature_Engineering_GIS
03_Pseudo_Ausencias_Dataset
04_Modelado_Au
05_Spatial_Validation
06_SHAP_Interpretacion
07_Mapas_Prospectividad_Au

La idea es buena, pero yo cambiaría el orden porque **la validación no puede ser algo que hacemos después de modelar.**

Debería formar parte del diseño del dataset antes del entrenamiento.

Mi arquitectura sería:

Notebook	Finalidad
00_Config_Proyecto_Au	CRS, resolución, rutas, semillas, parámetros globales
01_Auditoria_BDMIN_Au	positivos, duplicados, clusters, calidad de etiquetas
02_Grid_Espana_Au	crear unidad espacial única
03_Harmonizacion_Capas	CRS, resolución, extent, NoData, alineación
04_Features_Geologia_Estructural	fallas, contactos, litología, pliegues
05_Features_Geoquimica	Au/As/Sb/Bi/etc.
06_Features_Geofisica_Topo	geofísica + DEM + hidrología
07_Grid_Master_Au	matriz X de todo el territorio
08_PU_Background	pseudo-ausencias/PU y replicaciones
09_Spatial_Folds	blocking + buffers + domains
10_Baselines_Au	Logistic + RF + ExtraTrees
11_Boosting_Au	XGB + LightGBM + CatBoost
12_Nested_Spatial_CV	comparación rigurosa
13_Interpretacion_SHAP	importancia, SHAP, estabilidad
14_Calibracion_Incertidumbre_AOA	fiabilidad y extrapolación
15_Mapas_Prospectividad_Au	mapas finales

Ese sería ya un pipeline bastante próximo a producción.

50. El flujo completo, reducido a una sola ecuación mental

Quiero que te quedes con esto porque resume todo el proyecto:

Mapas GIS $\rightarrow$ *Grid* $\rightarrow$ *X* $\rightarrow$ (*P,U*) $\rightarrow$ *Spatial CV* $\rightarrow$ *f(X)* $\rightarrow$ *OOF validation* $\rightarrow$ *Interpretation* $\rightarrow$ *Prospectivity + Uncertainty*

boxed{ \text{Mapas GIS} \rightarrow \text{Grid} \rightarrow X \rightarrow (P,U) \rightarrow \text{Spatial CV} \rightarrow f(X) \rightarrow \text{OOF validation} \rightarrow \text{Interpretation} \rightarrow \text{Prospectivity + Uncertainty} }

Y cada parte significa:

Mapas GIS: las capas que ya tenéis.

Grid: unidad estadística homogénea.

X: transformar geología en números y categorías.

P,U: distinguir presencia conocida de territorio no etiquetado.

Spatial CV: impedir que el modelo haga trampas mediante proximidad.

f(X): Logistic/RF/XGB/LGBM/etc.

OOF: predicciones hechas sobre zonas nunca utilizadas para entrenar.

Interpretation: descubrir qué factores sustentan la predicción.

Prospectivity: mapa de favorabilidad.

Uncertainty: mapa de cuánto podemos confiar en esa favorabilidad.

51. Cómo entendería entonces `predict_proba`

La frase del PDF:

```
p_au = model.predict_proba(X_grid)[: ,1]
```

es correcta operativamente.

Pero conceptualmente yo escribiría:

$$s(x)=f(X)s(x)=f(X)$$

y llamaría inicialmente a s :

prospectivity score | *boxed*{ | *text*{*prospectivity score*}}

Una celda con:

$$s=0.90s=0.90$$

es más favorable según el patrón aprendido que otra con:

$$s=0.20s=0.20$$

Eso sí podemos decir con bastante claridad.

Lo que todavía no podemos afirmar es:

90 % de probabilidad física de que exista un yacimiento.

El propio PDF advierte correctamente de esta diferencia.

52. Qué copiaría del notebook del vino y qué no

Esta es probablemente la síntesis más importante.

Elemento	¿Copiar?	Adaptación necesaria
Pipeline	Sí	fundamental

ColumnTransformer	Sí	adaptar categorías geológicas
SimpleImputer	Sí	pero solamente dentro del pipeline
StandardScaler	Sí	solo modelos que lo necesitan
OneHotEncoder	Sí como baseline	controlar cardinalidad
Logistic Regression	Sí	baseline interpretable
Decision Tree	Sí	baseline didáctico
Random Forest	Sí	baseline fuerte
Extra Trees	Sí	añadirlo
XGBoost	Sí	candidato principal
LightGBM	Sí	candidato principal
CatBoost	Lo añadiría	categorías complejas
SVM	Posiblemente	benchmark secundario
train_test_split aleatorio	No	espacial
StratifiedKFold	No	spatial groups
GridSearch convencional	No	nested spatial
Accuracy como principal	No	PR + spatial targeting
ROC-AUC sola	No	PR-AUC + otras
Pseudo-ausencia única	No	múltiples backgrounds/PU
Permutation importance	No como principal	spatial OOF
TRAIN	Más adelante	calibración + spatial CV
Soft Voting	No	
Stacking cv=3	literalmente	spatial OOF stacking
predict_proba	Sí	llamarlo score/favorabilidad
Imputación global del notebook	No	es leakage

53. Mi evaluación final del PDF

La idea central del documento:

«lo que cambia radicalmente no son los algoritmos, sino cómo construimos X/y y cómo validamos»

es absolutamente la frase correcta con la que cerrar el documento.

De hecho, después de analizar los tres archivos, la reforzaría:

Calidad del modelo $\approx$ *calidad de labels* + *calidad de features* + *diseño de background* + *validación espacial* \boxed{ \text{Calidad del modelo} \approx \text{calidad de labels} + \text{calidad de features} + \text{diseño de background} + \text{validación espacial} }

y solo después:

+ *algoritmo* + \text{algoritmo}

El PDF acierta especialmente en cuatro cosas: identificar el problema de pseudo-ausencias/PU, rechazar validación aleatoria, no interpretar predict_proba como probabilidad geológica absoluta y considerar RF/XGBoost/LightGBM como candidatos en lugar de asumir que un algoritmo es ganador. Eso además concuerda con trabajos específicos de MPM que continúan señalando la escasez de positivos, ausencia de negativos fiables y dependencia espacial como problemas centrales.

Lo que le falta para convertirse en una metodología realmente sólida es, sobre todo, **definir la rejilla/resolución, auditar los labels, controlar el sesgo de exploración, diseñar rigurosamente las pseudo-ausencias, utilizar nested spatial CV, tratar la incertidumbre, estudiar extrapolación/AOA y evaluar la eficiencia espacial de los targets**, no solamente métricas clásicas de clasificación.

Y hay una corrección práctica inmediata: **no debemos reproducir la imputación global del notebook del vino**, porque las medianas se calculan antes del split. En el proyecto mineral toda transformación dependiente de los datos debe quedar encapsulada dentro del pipeline/fold.

El siguiente paso lógico ya no sería programar Random Forest. Sería definir **exactamente cómo construir Grid_Master_Au**, columna por columna: resolución de la rejilla, target_Au, tratamiento de indicios duplicados, diseño de background y todas las features que debemos extraer de cada una de las capas de CAPAS .pdf. Esa es la pieza que debe quedar cerrada antes de entrenar el primer modelo.