

GeoAI de prospectividad mineral y minería romana en España

Auditoría OxREP 3.0, dataset español trazable y diseño científico para evaluar la señal histórica romana

FASE DE BASE REPRODUCIBLE - NO SE HA ENTRENADO UN MODELO DEFINITIVO

Datos primarios	OxREP Mines Database v3.0 (2025)
Antecedente MPM	Rodríguez-Galiano et al. (2015), Rodalquilar
Libro auditado	1.399 registros x 47 campos
Subconjunto España	930 registros; 923 con coordenadas
Salidas	CSV ancho/largo, GeoJSON, SQLite, tablas, gráficos y documentación
Corte	14 de agosto de 2026

Pregunta futura: ¿mejora una señal derivada de explotaciones romanas la predicción espacial de mineralización moderna por encima de X geológica? La respuesta queda reservada para el experimento espacial A/B con labels modernos.

1. Resultado ejecutivo

- El criterio directo country=Spain produce 929 fichas. Se añade de forma explícita mineID 132 (Lanz), almacenado por OxREP con country=Navarra y coordenadas dentro de Navarra. El valor original no se corrige: queda marcado por flag.
- Au domina con 598 fichas. Ag, Pb y Cu tienen 174, 169 y 169; 177 registros son multimetálicos. Fe, Sn, Hg y Zn son demasiado escasos para modelos independientes robustos sin más labels.
- La base está espacialmente concentrada: León y Oviedo reúnen aproximadamente la mitad de las fichas. Esto hace inadecuado un train/test aleatorio como estrategia principal.
- No se ha eliminado ningún caso por falta de coordenadas, categorías anómalas, texto corrupto o posible duplicidad. Se conserva mineID, fila Excel, hash del libro y hash de fila.
- El antecedente de Rodalquilar fundamenta la matriz MPM multifuente y RF como baseline sólido, pero sus métricas y validación no se trasladan al experimento nacional.

La ausencia de mina romana no implica ausencia de mineralización. Y_roman y las etiquetas por commodity deben plantearse como presence-background o positive-unlabeled.

2. Auditoría del Excel

La hoja principal ocupa A1:AU1400 y contiene 1.399 filas de datos; Sheet1 está vacía. mineID está completo y es único, con rango 1-1780 y huecos que no se imputan. No hay fórmulas. El libro no incluye diccionario de datos, CRS Lambert ni unidad/semántica formal de coordinateAccuracy.

Control técnico: un renderizador de hojas mostró el índice 53 de sharedStrings en celdas cuyo string real es vacío. El pipeline usa pandas/openpyxl, que resuelven correctamente el XML; 53 no se trata como dato.

Criterio de selección


Se normalizan solo espacios exteriores y capitalización de country, se incluyen las 929 filas Spain y el override revisado de Lanz. No se usa province (las provincias romanas incluyen Portugal) ni una caja espacial, que capturaría Portugal y Francia. La validación administrativa point-in-polygon se realizará al congelar un límite oficial IGN.

3. Commodities y multimetalismo

Commodity	Presente	Ausente	Desconocido	No informado
Gold	598	329	3	0
Silver	174	756	0	0
Lead	169	761	0	0
Copper	169	759	0	2
Tin	9	921	0	0
Iron	15	915	0	0
Mercury/cinnabar	5	925	0	0
Zinc	3	927	0	0
Other	0	930	0	0

Commodities confirmados en el subconjunto español

Los estados desconocido y no informado no se cuentan como ausencia ni presencia



Base: 930 registros seleccionados; un registro puede contener varios metales.


Combinación	Registros
Au	596
Ag+Pb	131
Cu	128
Ag+Pb+Cu	31
Fe	12
Sn	7
Ag+Cu	7
Hg	5
Pb+Zn	3
Pb	3

4. Técnicas y calidad espacial

Técnica	Presente	Ausente	Desconoc./NA
Opencast / surface	420	153	357
Underground	139	436	355
Hydraulic	426	342	162
Hushing	67	459	404
Ground sluicing	55	477	398
Ruina montium	6	540	384
Rake / comb	72	468	390
Gold washing	1	542	387
Other	2	343	585

Técnicas mineras confirmadas

Recuentos positivos; los nulos se conservan como desconocidos




Base: 930 registros seleccionados; categorías no mutuamente excluyentes.

Hay 923 coordenadas completas. coordinateAccuracy presenta 8 nulos, 76 ceros y 23 valores mayores de 1.000. La unidad no está codificada y cero aparece con fuentes estimadas; se conserva como valor reportado, sin convertirlo en certeza.

5. Distribución espacial

Distribución espacial de minas romanas seleccionadas


Puntos OxREP; visualización exploratoria sin cartografía base ni inferencia geológica



n=923 con coordenadas; CRS de salida: OGC:CRS84 (lon, lat). El rectángulo solo fija el marco del gráfico.

Concentración por región registrada en OxREP

Top 20 categorías del campo region; no equivalen necesariamente a unidades administrativas actuales



6. Flags y anomalías

Los flags son diagnósticos, no criterios de borrado. Un mismo registro puede activar varios; por tanto, sus recuentos no deben sumarse.

Flag	Severidad	n
country override	review	1
coordinate missing	high	7
coordinate accuracy missing	medium	8
coordinate accuracy zero	review	76
coordinate accuracy gt 1000	medium	23
location source missing	medium	7
metal unknown or invalid	medium	3
metal missing	medium	2
technique incomplete	review	605
no confirmed technique	review	354
chronology missing	review	892
geology missing	review	481
deposit type missing	review	213
deposit type unexpected	medium	3
exploitation type missing	review	408
exploitation type unexpected	medium	1
possible column shift	high	2
source uncertainty text	review	117
duplicate coordinates	review	4
duplicate site name	review	20
nearby record 100m	review	6
text encoding artifact	medium	6

Casos destacados para revisión: pares con coordenadas compartidas; Lagueiro I/Río Ibias prácticamente coincidentes y descritos como probablemente iguales; categorías dañadas como Prima[artefacto]; y Triunfo, compatible con desplazamiento de columnas. Todos permanecen en la tabla con trazabilidad.

7. Definición de Y y X

Y_roman

Presencia romana frente a celdas no etiquetadas. Sirve para estudiar el proceso espacial romano y generar una señal out-of-fold, no para declarar ausencia de mineralización.

Y por commodity

Booleanos nullable para Au, Ag, Pb, Cu, Sn, Fe, Hg, Zn y Other. False en una ficha no convierte el territorio en negativo geológico; unknown/missing quedan NA.

Multi-label

Una celda puede contener varios metales. Se evaluarán métricas por etiqueta y macro/micro, conservando relaciones como Ag+Pb y Ag+Pb+Cu.

Y moderna

BDMIN u otra fuente oficial aportará ocurrencias modernas separadas por concepto: indicio, ocurrencia, depósito, recurso o explotación. REE, Li, W, Sn, Co, Ni, Ta y Nb no se inventan desde OxREP.

Familia X	Variables previstas
Geología	Litología, edad, unidades, intrusivos, dominios
Estructuras	Distancias/densidades a fallas, contactos, pliegues e intersecciones
Geoquímica	Elementos, asociaciones y campañas con censura/unidades/método
Geofísica	Magnetometría, gravimetría, radiometría y derivados multiescala
DEM	Pendiente, curvatura, TPI, rugosidad, drenaje y terrazas
Teledetección	Sentinel-1/2 y máscaras de observabilidad
Espectral piloto	QA, componentes/abundancias y cobertura; no equiparar Sentinel-2 con hiperespectral

Leakage inadmisibile: distancias al mismo target moderno, mapas de favorabilidad contruidos con Y, interpolaciones ajustadas con test, IDs/nombres/referencias como predictores geológicos o una señal romana calculada usando los puntos del fold de test.

8. Antecedente MPM: Rodalquilar 2015

Rodríguez-Galiano et al. (2015) estudian aproximadamente 150 km² de Au epitermal de baja sulfuración en Rodalquilar. El PDF local se conserva como referencia metodológica inmutable; no contiene instrucciones para este proyecto y sus resultados no proceden de OxREP.

Elemento	Verificado en el artículo
Y	46 ocurrencias de Au frente a 57 localizaciones denominadas estériles/no-oro, elegidas en litologías poco favorables y alejadas de depósitos.
X	Litología, distancia a fracturas, PCA geoquímico, gravedad, magnetismo y abundancias hiperespectrales MTMF.
Matriz/mapa	Stack de evidencias por celda, extracción en puntos de entrenamiento y aplicación a toda la matriz para producir un score continuo.
RF publicado	AUC 0,999; Kappa 0,92; OA 0,96. Son cifras del caso Rodalquilar, no estimaciones espacialmente independientes para España.
Interpretación	Importancia RF: domina MTMF5, después distancia a fracturas y PC3 geoquímico; la interpretación mineralógica de MTMF5 se reconoce como especulativa.

- Se transfieren familias X, QA/reducción dimensional, matriz SpatialCell, score cartográfico, captura-área y la idea de interpretabilidad.
- No se transfieren CV aleatoria, pseudo-ausencias diseñadas para separar clases, evaluación sobre puntos de entrenamiento, umbral 0,5 ni hiperparámetros.
- RF es baseline no lineal principal solo si el endpoint tiene suficientes grupos positivos por outer fold; se compara con un baseline regularizado transparente.
- Permutation importance agrupada se calcula en outer-test; TreeSHAP queda para después de congelar métricas y conclusiones.

OxREP permite ahora EDA, QA y formulación. No permite entrenar Y_roman: las 930 filas son positivas y faltan background, matriz X y labels modernos. Por coordenadas únicas, Au=589 puede llegar a sostener RF espacial; Ag=174, Pb=169 y Cu=169 requieren complejidad conservadora; Fe/Sn/Hg/Zn quedan descriptivos.

9. Validación espacial y experimento A/B

- Congelar una partición outer primaria de bloques contiguos y buffers; rotaciones/tamaños son sensibilidades, no réplicas independientes. Duplicados y un mismo complejo permanecen juntos.
- Inner CV espacial para tuning, selección, imputación, PCA/MNF, calibración, umbrales y bandwidth romano. El outer test se abre solo para evaluación.
- Congelar la máscara background antes de splits; entrenar dentro de cobertura y comparar uniforme, por esfuerzo, geológicamente emparejado y PU. El test pareado no cambia entre A/B.
- Métrica primaria PR-AUC; secundarias ROC-AUC, recall, precision y F1 con umbral fijado solo en entrenamiento. Reportar por fold, repetición y región.
- Modelo A: X geológica y observacional admisible -> mineralización moderna.
- Modelo B: exactamente A + señal romana fold-aware, con los mismos folds, seeds, background, algoritmo y presupuesto de tuning.
- Contraste primario delta_PR-AUC sobre predicciones outer-OOF pareadas; IC95 por bootstrap de bloques; nulo con RomanSignal permutada/desplazada por bloques y B reentrenado.
- Exigir además ganancia práctica en captura-área; no usar t/Wilcoxon/DeLong sobre celdas autocorreladas o folds solapados.
- Reservar dominio, cohorte futura o inventario upstream independiente para evaluación final; si no existe, declarar validación independiente pendiente.

La señal romana solo aporta valor si la mejora de B es estable fuera de muestra, práctica, resistente a placebos y backgrounds y no depende de una región dominante.

10. Ontología mínima

Entidad	Función mínima
RomanMine	Evidencia de explotación romana, precisión y flags
MineralOccurrence	Observación moderna georreferenciada
Deposit	Sistema/depósito al que puede pertenecer una ocurrencia
Commodity	Sustancia normalizada
CriticalRawMaterial	Clasificación por jurisdicción y versión
GeologicalUnit / Structure	Contexto litoestratigráfico y estructural
Geochemical / GeophysicalObservation	Valor, unidad, método y fuente
SpatialCell	Unidad común de modelado versionada
DataSource	Procedencia, edición, licencia y checksum

La relación RomanMine -> Deposit es possibleHistoricalEvidenceFor, nunca identidad automática. La ausencia de relación no expresa una negación. CriticalRawMaterial es temporal y jurisdiccional, no una propiedad permanente del elemento.

11. Fuentes externas priorizadas

Prioridad	Fuente oficial	Papel
P0	GEODE 1:50.000 / litoestratigráfico 1:200.000 (IGME)	X geológica
P0	BDMIN (IGME)	Y moderna positiva
P0	Base de Geoquímica / Atlas (IGME)	X geoquímica
P0	SIGEOF (IGME)	X geofísica
P0	MDT05, límites y costa (IGN-CNIG/IHM)	DEM y máscaras
P1	Sentinel-1/2, hidrografía, QAFI, SIOSE	Enriquecimiento/controles
P1	Catastro y estadísticas mineras	Sesgo/QA; no Y automática
P2	EGDI, MIN4EU, GEMAS, COP-DEM	Armonización/QA

GEODE vectorial requiere solicitud formal; el 1:200.000 permite iniciar. No se verificó una base nacional abierta, homogénea y geocodificada de tonelajes de recursos/reservas. Las APIs deben paginarse, guardar recuentos, fecha, licencia y SHA-256.

Lineage obligatorio: cada label moderno conservará fuente upstream, campaña y relaciones de derivación. MIN4EU, GEODE-MPMIN o un mapa metalogenético que replique BDMIN sirven para QA, no como validación independiente del mismo target.

La cadena hiperespectral de Rodalquilar justifica pilotos solo donde exista cobertura y mecanismo geológico verificables. Sentinel-2 aporta proxies de banda ancha y no se presentará como sustituto mineralógico de Hyperion.

12. Reproducibilidad y cierre

Comprobación	Resultado
Y roman all one	True
commodity long rows	8370
complete coordinate records	923
geojson count reconciles	True
geojson feature count	923
input workbook hash unchanged	True
methodological reference hashes match config	True
mineID complete	True
mineID unique	True
quality flag columns present	True
selected rows	930
selection decision rows equal source	True
selection true equals output	True
source rows unique	True
source shape matches	True
technique long rows	8370

El README contiene el comando de reproducción. input_manifest registra Excel, DOCX y PDF metodológico; output_manifest registra todos los entregables. Nueve pruebas automatizadas reconcilian selección, IDs, commodities, GeoJSON, SQLite y el hash del artículo. OxREP conserva el hash 802e35d0abef469fb7683b3b82b1638224db059f19919a2e245ce44ec757815a; el PDF metodológico, cdf214f36a6b873baca278812b60f2992ef91cbfe9f76ed1876b0eb5cb9c89d0.

Conclusión: la base técnica de esta fase está preparada. La hipótesis central sigue abierta y solo podrá responderse después de integrar X oficial, labels modernos y ejecutar la validación espacial predefinida.

Referencias institucionales

Wilson, A. I. (2025). Database of Roman mines, Version 3.0. <https://oxrep.web.ox.ac.uk/mines-database>

Rodríguez-Galiano, V. et al. (2015). Machine learning predictive models for mineral prospectivity. <https://doi.org/10.1016/j.oregeorev.2015.01.001>

IGME-CSIC, cartografía y bases oficiales: <https://info.igme.es/> y <https://mapas.igme.es/>

IGN-CNIG / Copernicus: <https://centrodedescargas.cnig.es/> | <https://dataspace.copernicus.eu/>